

AI활용 데이터 사이언스 기초 1강

- 탐색적 데이터 분석

<https://docs.google.com/presentation/d/1Ixdzzg7a0QzctLejfYInkih0tIxaVVBNUiFK0M19x9A/edit?usp=sharing>

빅데이터

❑ 기존의 일반적인 소프트웨어나 컴퓨터로는 다루기 힘들 정도로 양이 방대하고, 형태가 다양하며, 매우 빠른 속도로 쏟아지는 데이터

❑ 3대 핵심 특징(3V)

❑ **규모 (Volume - 압도적인 양)**

엑셀 시트 하나에 들어가지 않는 수준을 넘어, 수천 대의 서버를 연결해야 저장하고 처리할 수 있는 테라바이트(TB), 페타바이트(PB) 단위의 데이터입니다.

❑ **다양성 (Variety - 온갖 형태의 데이터)**

정리된 표나 숫자(정형 데이터)뿐만 아니라 SNS 게시물, 사진, 동영상, 스마트폰 위치 정보, 공장 센서 신호(비정형 데이터), 음성, 소리, 음악 등 다양한 형태가 섞여 있습니다.

❑ **속도 (Velocity - 실시간 생성과 처리)**

매초마다 다량의 데이터가 끊임없이 생성되며, 이를 가치 있게 쓰려면 거의 실시간으로 수집하고 분석해야 합니다.

탐색적 데이터 분석

- 데이터 특징을 알기 위해 시각화와 탐색으로 데이터에 대해 알아가는 과정
- EDA(Exploratory Data Analysis)
 - i. 데이터에 대한 질문을 만든다.
 - ii. 데이터를 시각화, 변형 및 모델링하여 질문에 대한 답을 찾는다.
 - iii. 질문을 개선하거나 새로운 질문을 만들기 위해 학습한 방법을 사용한다.
- EDA - 규칙을 가진 형식적인 과정이 아니라 데이터에 대해 사고하는 과정
- 데이터 분석 전 데이터 품질에 대한 조사가 필요함 - EDA는 데이터 분석에서 우선적 위치를
- 데이터 정제를 위해 EDA의 다양한 도구 사용
- EDA는 단순한 체크리스트나 고정된 공식이 아니라, "데이터에 대해 생각하고 대화하는 반복적 사고 과정"
- 데이터 분석에서 흔히 하는 실수는 데이터를 받자마자 머신러닝 모델부터 돌리는 것
- [질문 생성 → 시각화/변형 → 답변 도출 → 새로운 질문 발견]으로 이어지는 순환 사이클이 필요

탐색적 데이터 분석 개요

질문하기

- EDA의 목표는 데이터를 이해하는 것
- 가장 적절한 접근 방법은 **많은 질문**을 사용하는 것
- 좋은 질문의 핵심은 많은 양의 질문을 생성하는 것에서 출발

데이터에 대한 두 가지 질문

- (a) 변수 내에서 어떤 유형의 변동이 발생하는가?
 - 변동(Variation): 단일 변수 내부에서 값들이 어떻게 흩어지고 퍼져 있는가? (단변량 탐색)
- (b) 변수 간에는 어떤 유형의 공변동이 발생하는가?
 - 공변동(Covariation): 두 개 이상의 변수가 서로 어떻게 얹혀 함께 움직이는가? (다변량/이변량 탐색)

EDA

EDA, exploratory data analysis

- 수집 데이터에 대한 탐색 exploratory search (↔ confirmatory work)
- 데이터의 특징과 구조적 측면을 파악하라

통계학에서 **탐색적 데이터 분석(EDA, Exploratory Data Analysis)**은 주로 통계 그래픽 및 기타 데이터 시각화 기법을 활용하여 데이터셋의 주요 특성을 요약하고 분석하는 접근 방식입니다. 통계 모델을 사용할 수도 있고 사용하지 않을 수도 있지만, EDA는 주로 정형화된 모델링을 넘어 데이터 자체가 무엇을 말해주는지 확인하는 데 목적이 있으므로 전통적인 가설 검정과 대비됩니다.

탐색적 데이터 분석은 1970년대부터 **존 튜키(John Tukey)**에 의해 주장되었으며, 통계학자들에게 데이터를 적극적으로 탐색하고 새로운 데이터 수집 및 실험으로 이어질 수 있는 가설을 수립하도록 장려했습니다.

EDA는 **초기 데이터 분석(IDA, Initial Data Analysis)**과는 구별됩니다. IDA는 모델 적합(fitting) 및 가설 검정에 필요한 가정을 검증하고, 결측치를 처리하며, 필요에 따라 변수 변환을 수행하는 등 보다 좁은 범위에 집중합니다. EDA는 이러한 IDA를 포괄하는 개념입니다.

— 위키백과(Wikipedia) 출처

What is EDA

EDA의 목표

- ✓ 관측현상에 대한 통찰(insight) → 가설생성
 - ✓ 어떤 통계적 추론이 가능한가? 추론에 요구되는 가정들을 검토
 - ✓ 통계적 도구 및 방법의 선택
 - ✓ 어떤 데이터가 추가로 필요한가?
-
- ❑ 데이터 패턴 파악을 통한 통찰 및 가설 도출
 - ❑ 통계 모델 적용을 위한 기본 가정(정규성, 등분산성, 선형성 등) 사전 점검
 - ❑ 문제 해결에 가장 적합한 모델/알고리즘 선정
 - ❑ 분석 한계 극복을 위해 추가 수집해야 할 피쳐(Feature) 파악



셜록과 왓슨의 대화

- 셜록 홈즈: 자네는 보기만 할 뿐 관찰을 하지 않아. 보는 것과 관찰하는 것은 완전히 달라. 예를 들면, 자네도 현관에서 이 방으로 올라오는 계단을 여러번 보았겠지?
- 왓슨 박사: 가끔 보았지.
- 셜록 홈즈: 몇 번이나 보았나?
- 왓슨 박사: 수 백 번은 보았을 거야.
- 셜록 홈즈: 그렇다면 모두 몇 계단인가?
- 왓슨 박사: 몇 계단? 모르겠는데.
- 셜록 홈즈: 그것 봐. 관찰하지 않았기 때문이야. 그러나 보기는 하지. 내가 말하고 싶은 것은 바로 그 점이야. 잘 듣게나. 나는 계단이 모두 열입곱 단이라고 알고 있어. 그것은 보는 것과 동시에 관찰하기 때문이야.

CDA VS EDA

확증적 데이터 분석(Confirmatory Data Analysis) VS 탐색적 데이터 분석(EDA)

- ❑ CDA : 전통적인 분석 방법으로, 가설을 먼저 설정한 후 수집한 데이터로 가설을 평가하고 추정하는 방식[연역적]
- ❑ EDA : 벨연구소의 수학자 'John Tukey'가 1970년 개발한 데이터분석 과정에 대한 개념[귀납적]
 - ❑ 두 방법론은 대립되는 것이 아니라, EDA로 가설을 발굴하고 CDA로 그 가설을 통계적으로 입증하는 상호보완적 관계

CDA VS EDA

- Confirmatory... 사전 제시된 차이·가설의 재현성(reproducibility)

✓ 신뢰구간, 가설검정 등 통계적 추론

- Exploratory... 차이·가설의 발견

✓ 데이터 마이닝 (data mining), 빅 데이터(big data)

예 :

- 감기에 걸리는 사람들과 감기에 걸리지 않는 사람들 간에 어떤 차이가 있는가를 수 십 가지 측면에서 살펴보았다.
- 그 결과, 비타민 C를 복용하는 사람들이 감기에 잘 걸리지 않음을 알게 되었다 [EDA].
- 그러면, 비타민 C를 복용하면 감기에 덜 걸리게 된다고 말할 수 있는가? EDA로 이에 대한 답을 하긴 어렵다. 잘 설계된 비교실험으로 새로 자료를 수집해 확인해 볼 필요가 있다 [CDA]

EDA의 4가지 주제

- 1) 저항성 resistance : 관찰된 일부의 지나친 영향력에 주의
- 2) 잔차 residual : 모범으로부터의 이탈(벗어남)에 주목
- 3) 재표현 re-expression : 같은 것도 다르게 표현할 것
- 4) 시각화 visualization : 그래프로 특징을 나타낼 것

1) 저항성

저항적인 자료 분석은 예외 데이터의 이상 변동에 따른 영향을 작게 받는다.

예 : 한 건물 9 가구의 TV 시청시간 자료

[8, 9, 6, 4, 12, 11, 11, 52, 8]

=> 평균 13.4 시간,

* 딱 1 가구의 시청시간 때문에 모두의 평균이 지나치게 올라감 ==> 저항적이지 않다.

=> 중앙값 9 시간

* 52시간 가구가 있어도 중앙값은 크게 변동되지 않음 ==> 저항적이다. (=이상값 영향이 작다)

2) 잔차


잔차는 개별 관측값이 자료의 주 경향으로부터 얼마나 벗어날 수 있는가를 말해준다.

主경향과의 편차. “실제가 기대와 어떻게 다른가를 본다”

예 1. 자료값 05, 08, 09, 10, 11, 15, 16, 19, 21, 29, 310 → ¹⁵ 중간값

잔차 - 10, -7, -6, -5, -4, 0, 1, 4, 6, 14, 295

↳ 특별히 다름



예 2. 단순선형회귀 사례

3) 재표현

데이터 분석 단순화를 위해 원래 변수를 적당한 척도(예, 로그 변환, 제곱근 변환, 역수 변환 등)로 변환

예 1. 지진파의 진폭(amplitude) → $\log_{10}$ Richter 척도


∴ 리히터 척도 7의 지진은 리히터 척도 6의 지진에 비해 10배의 진폭을 보임

예 2. 피아노 음계 == 1 옥타브에 12개 음이 있고 연이은 음은 진동수에서 $2^{1/12}$ 배 차이.

A - 440Hz
A# - 466.16Hz
차이 - 21.16
 $2^{1/12}$ 배


A 440Hz →
A#
B
C 523Hz
C#
D
D#
E
F
F#
G
G#
A 880Hz ← +1 옥타브

A - 880Hz
A# - 932.33Hz
차이 - 52.33
 $2^{1/12}$ 배



4) 시각화

자료 안 숨겨진 정보를 보여주는 효율적인 수단, 시각적 표현, 그래프, 인포그래픽




Power Transformation

변환 => 재표현

더하거나 곱하는 것으로
분포의 형태는 불변

- 선형 변환은 큰 의미를
가지기 어려움




Power Transformation

변환 => 재표현

제공근 변환은 분포형태 변형

- 제공근 변환은 큰 값일수록 압축되는 비율이 커지므로 오른쪽 길게 꼬리가 늘어진 분포를 대칭에 가깝게 퍼주는 효과가 있다.




Power Transformation

변환 => 재표현


로그 변환은 분포형태 변형

로그 변환 ($\log(x)$): 제곱근 변환보다 훨씬 더 강력하게 큰 값들을 압축

Histogram of x



Histogram of $\log(x, 10)$







Power Transformation

로그변환과 제곱근 변환의 차이

거듭곱(power) 변환 $y = \frac{1}{p} ((x + 1)^p - 1)$

데이터 왜곡의 강도에 따라 적절한 변환
단계를 선택하여 정규분포에 가깝게
조정하는 원리를 정리합니다



재표현의 목적

자료 재표현이 요구되는 경우

- (1) 여러 자료 묶음의 산포가 상이하여 그룹간 비교가 어려운 경우
 - 그룹 간 산포(Spread)를 일정하게 만들어 공정한 비교를 가능하게
- (2) 변수간 관계가 비선형인 경우
 - 곡선 형태의 비선형 관계를 직선 형태로 펴서 회귀 모델링 및 분석을 단순화


재표현의 목적

(1) 여러 자료 묶음의 산포가 상이하여 그룹간 비교가 어려운 경우

가입자들이 사고를 당하면 보상액을 청구하는 보험이 있다.


그래프는 한 보험회사가 판매한 3 종류의 보험 상품“A”, “B”, “C”에 대한 종별 보상 청구액 그래프이다. 이 그래프를 보면 각 종별로 **다른**

중심(center)과 **산포(spreadness)**를 갖는다는 것을 알 수 있다. 이와 같은 경우 우선적으로 산포를 균일하게 해주는 변환을 찾을 필요가 있다. 그래야 중심을 비교하기 쉽다.



재표현의 목적


(1) 여러 자료 묶음의 산포가 상이하여 그룹간 비교가 어려운 경우



제곱근 변환

상자의 길이가 비슷해 보이는 것으로 보아 자료 묶음의 산포가 균일해졌음을 알 수 있다.

제곱근 변환이 적절해 보인다.



로그 변환

“A”, “B”, “C”의 순서로 중앙값이 커지면서 산포는 반대로 작아져 보인다.


변환의 정도가 지나쳤다고 할 수 있다.

재표현의 목적


(2) 변수간 관계가 비선형인 경우

두 변수간의 관계가 변수 변환에 의하여 단순해지는 경우를 보도록 하자.

왼쪽 그래프는 x 와 y_1 이 불룩한 단조증가적 관계를 보인다. 이것은 y_1 에 제곱근 변환을 취함으로써 두 변수간 관계가 단순화 될 가능성을 보여준다.








오른쪽 그래프는 x 와 y_2 가 오목한 단조증가적 관계를 보인다. 따라서 y_2 에 제곱 변환을 취함으로써 두 변수간 관계가 단순화 될 수 있음을 알려준다.



재표현의 목적

(2) 변수간 관계가 비선형인 경우

두 변수간의 관계가 변수 변환에 의하여 단순해지는 경우



변환 전후 비교: 비선형 곡선 관계를 선형 관계로 변환했을 때, 단순 선형 회귀 분석이나 피어슨 상관계수 산출의 정확도와 해석력이 극대화됨을 시각적으로 확인

데이터 시각화

변동(variation)

- 변동은 변수의 측정값이 변하는 경향
 - 연속형 변수를 두 번 관측하면 두 개의 다른 결과 발생
 - 사물의 길이나 무게와 같은 일정(동일)한 양을 측정하더라도 변동이 발생됨
- 각각의 측정 값들은 서로 다른 약간의 오차를 포함
- 모든 변수는 흥미로운 정보를 나타낼 수 있는 고유한 변동 패턴을 가짐
 - 패턴을 이해하는 가장 좋은 방법은 변수값들의 분포를 시각화

분포 시각화

- 변수의 분포를 시각화 하는 방법은 그 변수가 범주형인지 연속형인지에 따라 다르다.


범주형(categorical) 변수

- 1) 유한개의 집합에서 하나의 값만 가질 수 있는 경우
- 2) 범주형 변수는 일반적으로 Factor 형이나 Character 형으로 저장
- 3) 범주형 변수의 분포를 확인하기 위해서는 막대 그래프를 사용

Variation 탐색을 위한 데이터 시각화

분포 시각화

- 막대의 높이는 각 x 값에 대한 관측값의 수를 나타낸다.




cut	n
<i><ord></i>	<i><int></i>
1 Fair	<u>1610</u>
2 Good	<u>4906</u>
3 Very Good	<u>12082</u>
4 Premium	<u>13791</u>
5 Ideal	<u>21551</u>

Variation 탐색을 위한 데이터 시각화

연속형 변수는

- 1) 순서가 있는 무한 집합에서 임의의 값을 가질 수 있는 변수
- 2) 숫자와 시간은 연속형 변수의 대표적인 변수
- 3) 연속형 변수의 분포를 확인하기 위해서는 히스토그램을 사용


```
# A tibble: 11 x 2  
  `cut_width(carat, 0.5)`    n  
  <fct>                  <int>  
1 [-0.25,0.25]             785  
2 (0.25,0.75]            29498  
3 (0.75,1.25]            15977  
4 (1.25,1.75]             5313  
5 (1.75,2.25]             2002
```



Variation 탐색을 위한 데이터 시각화

분포시각화


- 히스토그램은 x축을 동일 간격의 bin(구간)으로 나누고, 각각의 bin에 해당하는 관측값의 수를 표시하기 위해 막대의 높이를 사용
- x 변수의 단위로 측정된 binwidth 인수로 히스토그램의 간격의 폭을 설정
- Bin의 너비(구간 너비)에 따라 패턴이 달라질 수 있으므로 다양한 bin 너비를 탐색



Variation 탐색을 위한 데이터 시각화

분포시각화

- 같은 플롯에서 여러 히스토그램을 겹쳐서 그릴수도 있음
- 빈도수를 나타낼 때 막대대신 선을 사용할 수도 있음




Variation 탐색을 위한 데이터 시각화

일반적인 값

그래프가 보여주는 정보를 비즈니스에 유용한 질문으로 전환하기 위해 데이터에 대해 질문하는 방법


- 어떤 값이 가장 일반적인가?
그 이유는 무엇인가?
- 드물게 나타나는 값은 무엇인가?
그 이유는 무엇인가?
예상과 일치하는가?
- 비정상적인 패턴을 볼 수 있는가?
그 패턴을 설명할 수 있는가?



Variation 탐색을 위한 데이터 시각화

앞 페이지의 히스토그램을 이용하여 만들수 있는 질문 예시

- 전체 캐럿 중 일부 캐럿에 해당하는 다이아몬드가 많은 이유는 무엇인가?
- 각 최고점의 오른쪽 부분에 왼쪽 부분보다 더 많은 다이아몬드가 있는 이유는 무엇인가?
- 3 캐럿보다 큰 다이아몬드가 없는 이유는 무엇인가?




Variation 탐색을 위한 데이터 시각화

일반적으로 유사한 값들의 군집은 데이터 내에 하위 집단이 있다는 것을 의미
하위 집단을 이해하기 위하여 다음과 같은 질문을 할 수 있다.

- 각 군집 내의 관측값은 서로 유사한가?
- 각 군집은 서로 다른 클러스터의 관측값과 다른가?
- 군집은 어떻게 설명하거나 묘사할 수 있는가?
- 군집의 모양이 오해의 소지가 있는 이유는 무엇인가?

Yellowstone 국립공원의 Old Faithful Geyser 에서 발생한 272번의 화산 분출 히스토그램을 보면, 짧은 분출(2분)과 긴 분출(4~5분)이 있고 그 중간에는 값이 거의 없다. 따라서 2개 그룹으로 묶인 것처럼 관측된다.


이봉 분포(Bimodal Distribution) 해석: 엘로스톤 간헐천 데이터처럼 봉우리가 2개 나타나는 경우, 데이터 안에 성격이 완전히 다른 두 개의 하위 집단(Sub-population)이 섞여 있음을 의미
-> 단일 평균으로 요약하지 말고, 데이터를 두 그룹으로 나누어 총화 분석



Variation 탐색을 위한 데이터 시각화

이상값(outlier)

- 이상값은 패턴에 맞지 않은 데이터 값으로 비정상적인 관측값
- 이상값은 데이터 **입력 오류**인 경우가 있으나, 때에 따라서는 **중요한 새로운 정보**를 제시
 - 이상 거래, 특이 사건 등
- 히스토그램에서 이상값을 발견하기는 쉽지 않음
- 아래 히스토그램에서 이상값의 단서가 되는 것은 y 축의 범위가 매우 넓다는 것
 - 극단적 이상치가 존재할 확률이 높음



Variation 탐색을 위한 데이터 시각화


이상값 탐색

- 이상값이 결과에 최소한의 영향을 미치고 왜 이상값이 발생했는지 이유를 알 수 없다면 결측값으로 대체하고 분석을 진행하는 것이 합리적
- 그러나 이상값이 결과에 상당한 영향을 미친다면 타당한 이유없이 제외하는 것은 안된다. 문제의 원인을 파악해야 한다

Variation 탐색을 위한 데이터 시각화

결측값 탐색

- 하나의 측정값이 유효하지 않다고 해서 모든 측정값이 유효하지 않은 것은 아니므로 이상값이 포함된 행 전체를 삭제하는 것은 좋은 방법이 아님
- 저품질의 데이터가 수집 상황일 때 이 방법을 적용하면 데이터가 거의 남지 않을 것
- 이상값을 결측값으로 변경하는 방법 권장




공변동 탐색을 위한 데이터 시각화

공변동 시각화

- 변동이 변수 내의 움직임을 설명한다면 공변동은 변수들 간의 움직임을 설명한다.
- 공변동은 둘 이상의 변수값이 연관되어 동시에 변하는 경향을 말한다.
- 공변동을 관측하기 가장 좋은 방법은 두 개 이상의 변수 사이의 관계를 시각화하는 것

범주형 변수와 연속형 변수

- 그래프의 기본 모양으로 높이가 빈도수를 나타내는 것은 이러한 종류의 비교에는 유용하지 않다. 즉, 그룹 중 하나가 다른 값들보다 월등히 작거나 크다면 형태의 차이를 파악하기가 어렵다.
- 오른쪽 그래프는 전체의 빈도수가 다르므로 분포의 차이를 파악하기 어렵다.




공변동 탐색을 위한 데이터 시각화

공변동 시각화 개요

범주형 변수와 연속형 변수


- 비교를 쉽게 하기 위해서 y 축에 표시된 내용을 변경할 필요가 있다.
- 빈도수를 나타내는 대신에 빈도 다각형 아래의 영역이 1이 되도록 빈도수를 표준화한 밀도로 나타내는 작업이 필요



공변동 탐색을 위한 데이터 시각화

범주형 변수와 연속형 변수


- 범주형 변수를 구분된 연속형 변수의 분포로 나타내는 또 다른 방법은 상자그림(boxplot) 이다.
- 상자그림은 값의 분포를 시각적으로 간편하게 보여줄 수 있는 형태이다.
- 상자그림은 다음의 것들로 구성된다.
 1. 사분위수 범위(IQR)라고 알려진 25번째 백분위수에서 75번째 백분위수까지 상자로 표현
 2. 분포의 중앙값(50분위수, median)은 상자의 가운데 위치한 선
 3. 상자의 가장자리에서 1.5배 이상 떨어진 관측값 점은 일반적이지 않으므로 별도 표시
 4. 상자의 양끝에서 뻗어 나와 가장 멀리 떨어진 이상값이 아닌 점에서 이어진 선



공변동 탐색을 위한 데이터 시각화

범주형 변수와 연속형 변수


- 앞 페이지의 상자그림에서 x축의 cut은 Fair < Good < ... < Ideal 로 순서가 있지만, 대부분의 범주형 변수는 고유한 순서가 없다.
- 따라서 순서를 변경하여 더 유용한 정보를 주도록 표현할 수 있다.
- 예를 들어, mpg 데이터셋의 class 변수를 기준으로 자동차의 종류에 따라 고속도로 주행 거리 변화를 알아보고자 한다




공변동 탐색을 위한 데이터 시각화

범주형 변수와 연속형 변수

- 추세를 쉽게 파악하기 위해 hwy 변수의 중앙값을 기준으로 class 변수의 순서를 변경



- x축과 y축을 바꾸어서 표현할 수도 있다



....**END**